TechVi


Machine Learning Project

DIABETES PREDICTION

Alè OUATTARA



COMPREHENSION DU PROBLEME




COLLECTE

EXPLORATION

PREPROCESSING

MODEL- EVALUATION-OPTIMISATION

COLLECTE DES DONNEES



https://archive.ics.uci.edu/dataset/891/cdc+diabetes+health+indicators



Statistiques descriptive :



Statistiques descriptive :

Socio-Démographique

Genre

Femme = 56%

Education

Diplôme Secondaire = 94,6%

AGE

45-69 = *50*%

Etat de santé

Santé Générale

82,9% affirme être au moins en bonne santé

Diabete

86,1% sans diabète

Facteurs de risque

IMC

IMC moyen 28,4


Activité physique


75,7% ont fait des activités physiques

Fumeur

55,7 % ne fument pas







Coefficient de corrélation bisériale

MentHlth 0,069

PhysHlth 0,17


GenHlth 0,293
Income -0,163


0,216

BMI

Encodage 03 OneHotEncoding **Normalisation** 02 Standarscaler Valeur manquante **Data cleaning**

Features Selection







Model- Evaluation

RandomForest Adaboost KNN

Choix du model

Modèle	Accuracy	Recall	F1 Score
Random Forest	0.8555	0.1534	0.2318
AdaBoost	0.7563	0.7032	0.4506
KNN	0.7074	0.6357	0.3818




Split Data 80/20

Choix des métrics


Accurancy Recall F1_score

Données déséquilibré : Oversampling

Modèle	Accuracy	Recall	F1 Score
Random Forest	0.8555	0.1534	0.2318
AdaBoost	0.8600	0.1900	0.2900
KNN	0.8500	0.2100	0.2800



O P T I M I S A T I O N



Accuracy	Recall	F1 Score
0.7959	0.6039	0.4569

P R E D I C T I O N

Voir NoteBook

